

知能情報システム

第8回 機械学習 教師あり学習 (その1)

秦野 亮


東京理科大学 経営システム工学科

2025

本日の講義内容

教師あり学習について学ぶ。

1. 教師あり学習の概要
2. 基本的な線形分類モデル



モデル関連の図表は以下の文献に依るものです：

S. Raschka, V. Mirjalili, Python Machine Learning 3rd Ed., Impress, 2020.²

教師あり学習 再掲

- ・ システム外部からの教師信号(ラベル)による
教示によって学習を行う。



例：手書き数字の認識

学習フェーズ

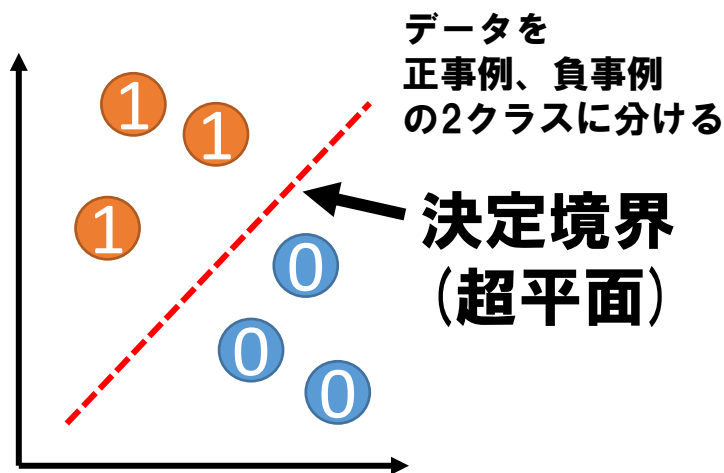
サンプル	1	2	3	7	1	2	1	7
ラベル	1	2	3	7	1	2	1	7




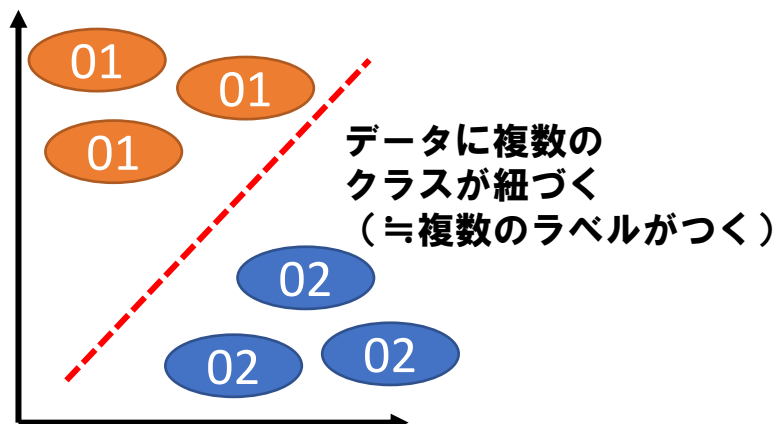

予測フェーズ

これは何でしょう？₃

主な教師あり学習の分類



二値分類



データセットの形式


特徴量 (説明変数)

ラベル (目的変数)

Sample No.	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
⋮	⋮	⋮	⋮	⋮	⋮
51	7.0	3.2	4.7	1.4	Versicolor
⋮	⋮	⋮	⋮	⋮	⋮
150	5.9	3.0	5.1	1.8	Virginica

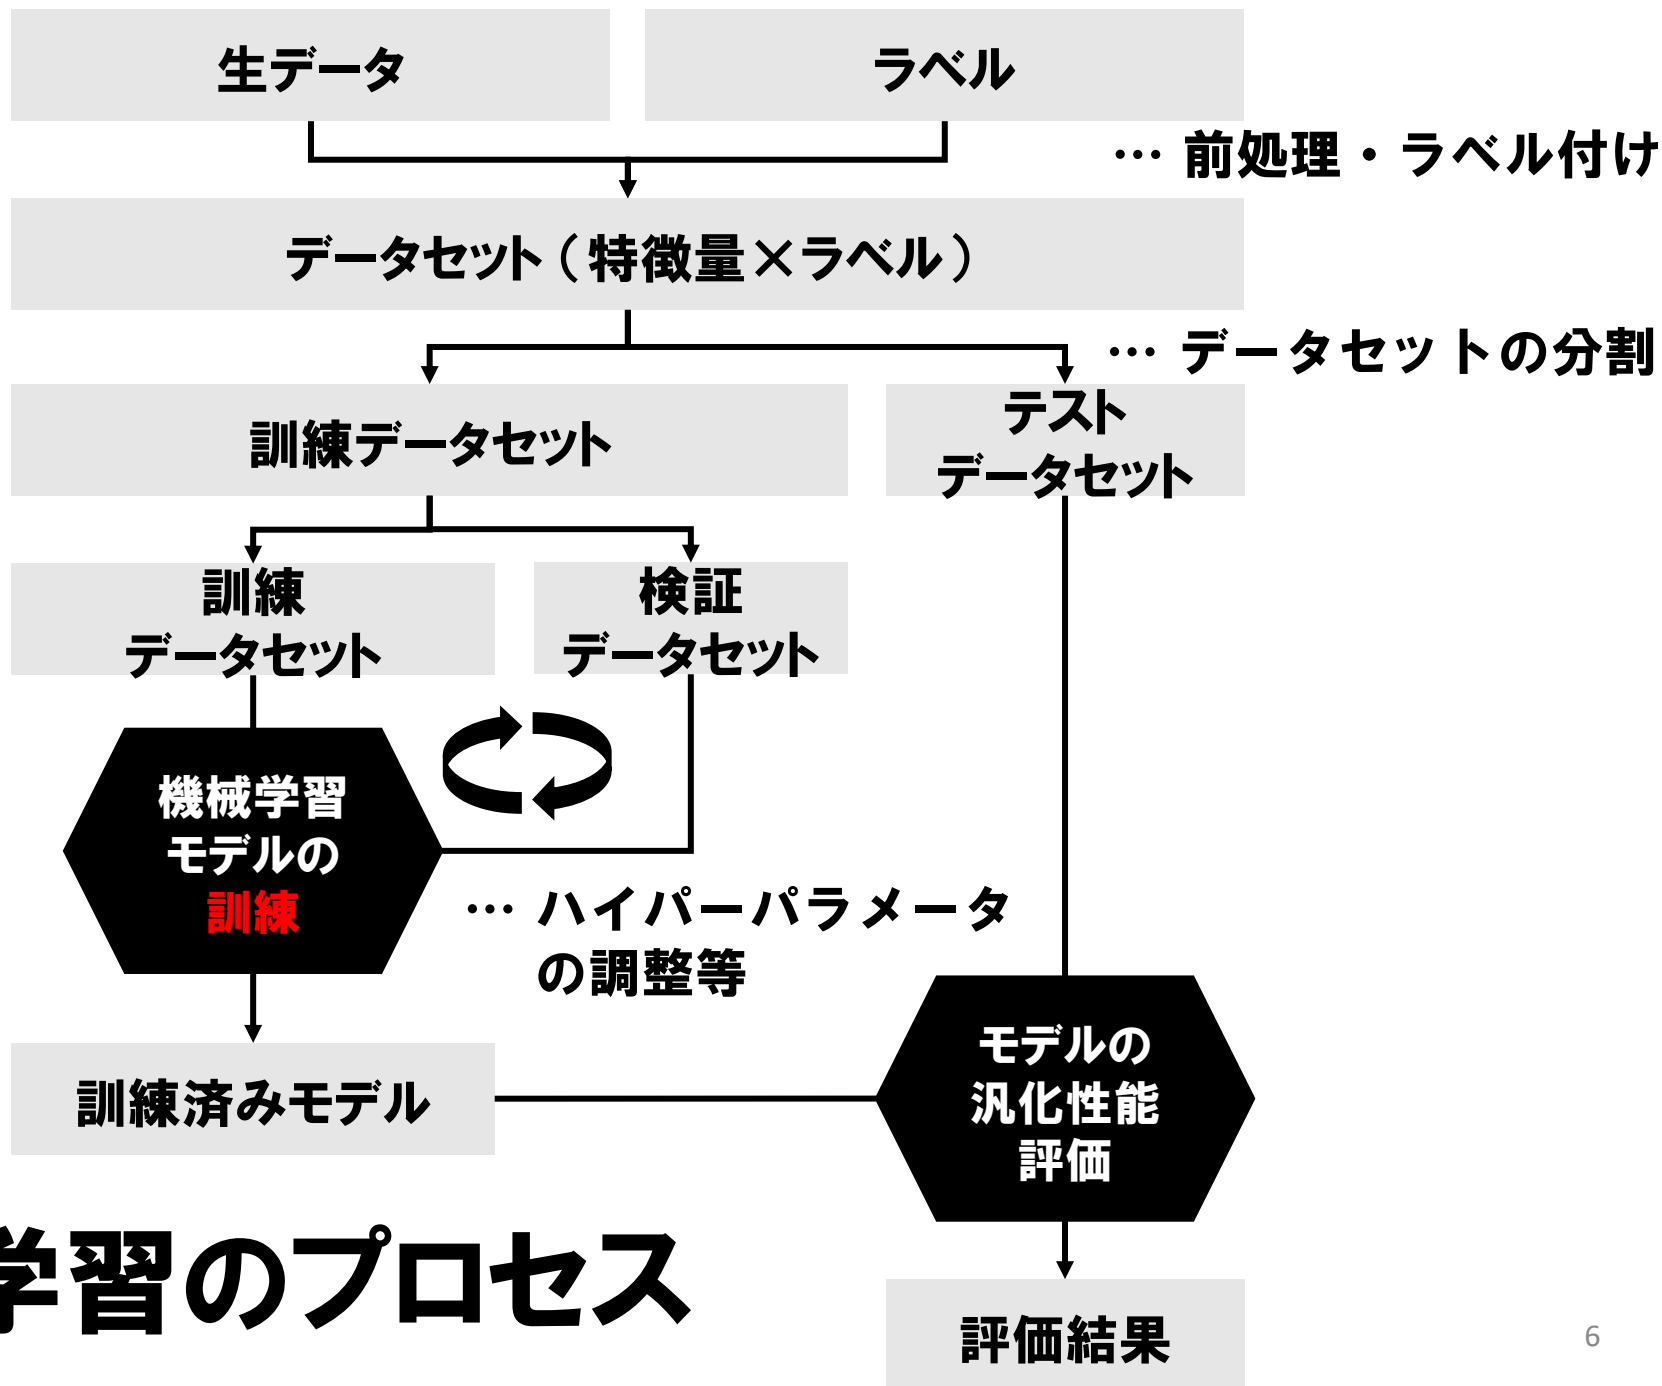
サンプル (インスタンス)

※width/lengthの単位はcm



上記の例は「あやめ (花菖蒲)」の分類に関するデータセットです。

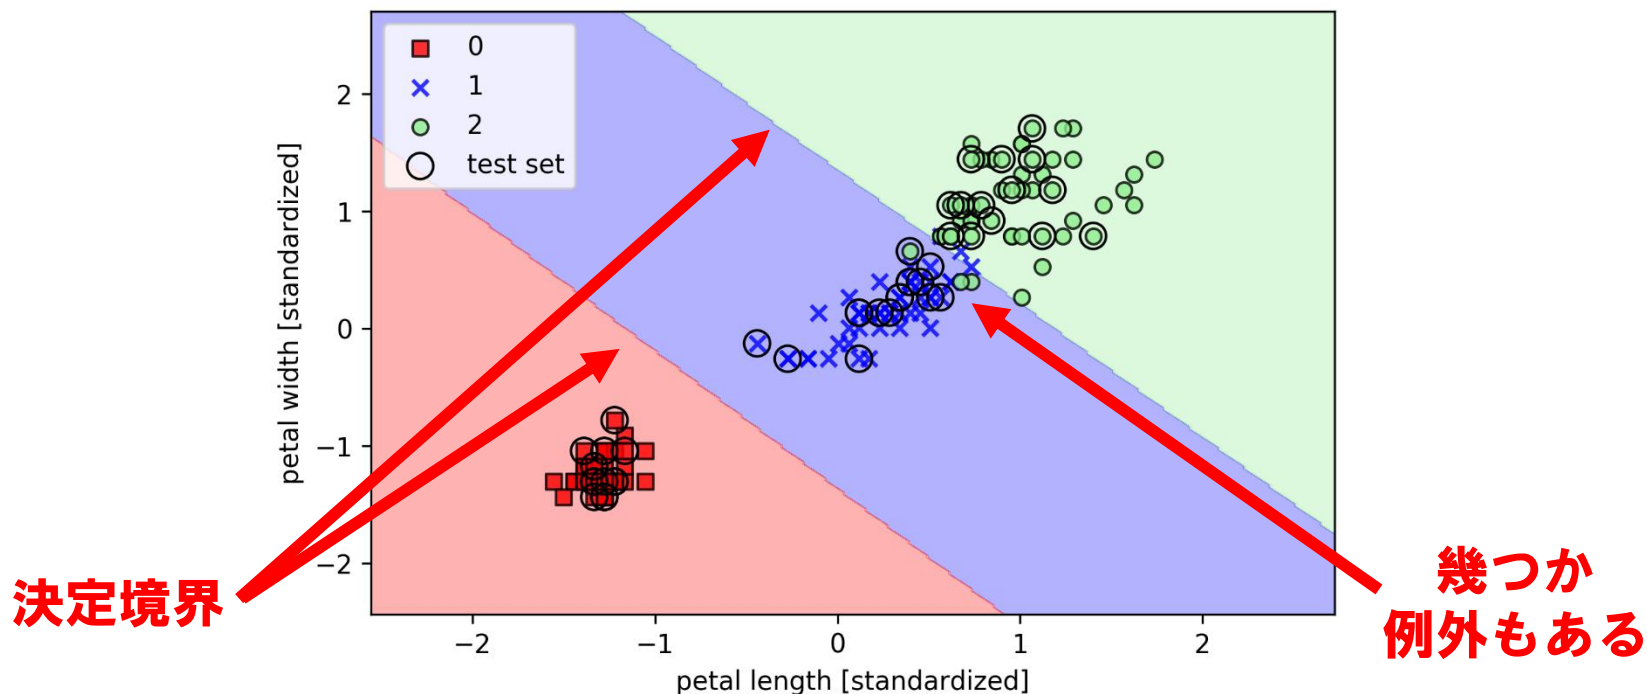
出典: Iris Dataset, <https://archive.ics.uci.edu/ml/datasets/Iris>



学習のプロセス

うまく訓練できたモデルの例


前出のデータセットから、
以下の様な多値分類モデルを得ることができる。




この様な分類の仕方を**線形分離**と呼ぶ。

Quiz: 訓練してみよう


線形分離できるでしょうか？




解答例



ϕ



ϕ^{-1}



普通にやると**出来ません**。
決定境界が曲線を含む
 \Rightarrow **非線形分離**です。


なお、**特別**な射影関数 ϕ を
導入し、高次元空間に
データを写像すれば
そこで**線形分離出来る**
…こともあります。

カーネル法 (SVM) を用いた
分類の例です。

様々な教師あり学習のモデル


- パーセプトロン、ロジスティック回帰
- ナイーブベイズ分類器、隠れマルコフモデル
- サポートベクトルマシン、条件付き確率場
- 決定木、帰納論理プログラミング
- アンサンブル学習
 - Bugging、ランダムフォレスト、XGBoost、LightGBM
- (深層)ニューラルネットワーク etc. 他にもいっぱいあります。
用途に応じて使い分けます。

「決定境界の引き方」
が違うだけのかな？



Perceptron

パーセプトロン



W. McCulloch

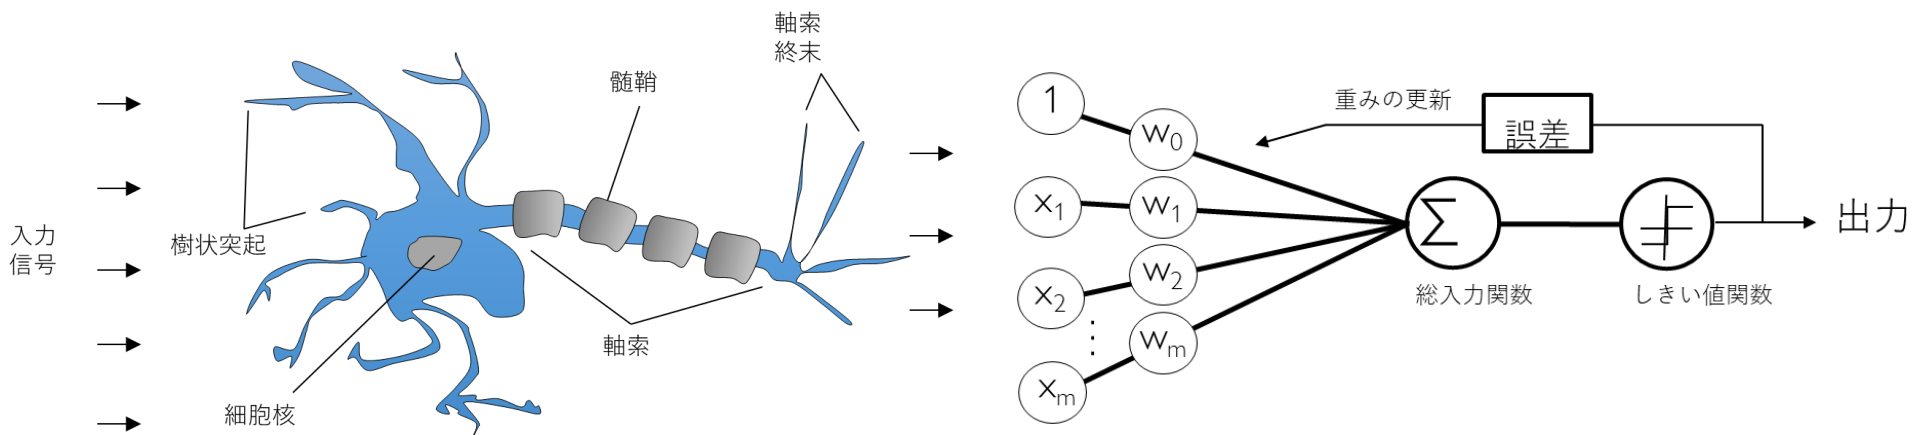


W. Pitts



F. Rosenblatt

- 人間の脳細胞の基本単位となる「ニューロン」の動作を模した機械学習モデル
- 1943年のW. McCulloch & W. Pittsらにより提案された「形式ニューロン」のアイデアに基づき、1958年にF. Rosenblattが学習規則を与えた。

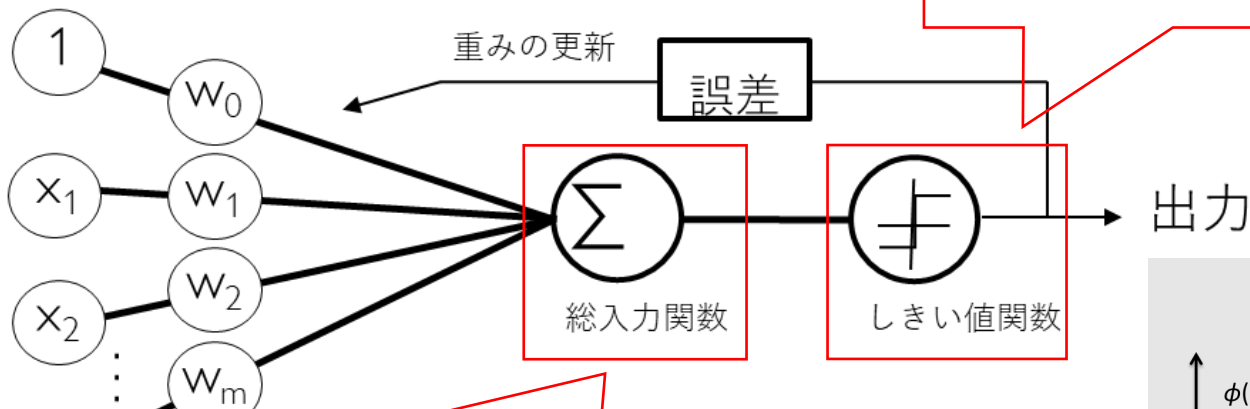


パーセプトロンのモデル


刺激 (≡入力) によってニューロンが
発火する or しない (≡出力)
仕組みを模している。

単位ステップ関数

$$\phi(z) = \begin{cases} 1 & \text{if } z \geq 0, \\ -1 & \text{if } z < 0. \end{cases}$$



$$\begin{aligned} z &= w_0 x_0 + w_1 x_1 + \dots + w_m x_m \\ &= \sum_{j=0}^m w_j x_j = \mathbf{w}^T \mathbf{x} \end{aligned}$$



※上記の図ではモデル式導出の関係で $x_0 = 1$ としています。

パーセプトロンの学習規則

1. 重みベクトル w を初期化する (0 or 乱数)
2. 各訓練データ x^i ごとに以下の計算をする:

1. 予測値 \hat{y}^i を計算する:

$$\hat{y}^i = \phi(z^i),$$

ただし $z^i = w^T x^i$ である。

2. 重みベクトル w 中の各重み w_j を更新する:


$$w_j := w_j + \Delta w_j$$
$$\Delta w_j = \eta (y^i - \hat{y}^i) x_j^i$$

ただし、 η は学習率 (0～1の実数値)、
 y^i は訓練データ x^i の真のラベル、
 \hat{y}^i は訓練データ x^i の予測値のラベルである。

要するに、試しに予測して駄目なら重み w を更新するということ。



手を動かしてみよう！




- いま、重み $w = \begin{bmatrix} 0 \\ 0.5 \\ 1 \end{bmatrix}$ のパーセプトロンの
モデルが与えられている。
- このモデルを学習率 $\eta = 0.5$ で学習させたい。
そこで訓練データ $x = \begin{bmatrix} 1 \\ 1 \\ 0.5 \end{bmatrix}$ と真のラベル $y = 1$ の

ペアを用いて学習を試みて、以下の予測値 \hat{y} が
得られた場合の重み w の更新を行いなさい。

- (1) $\hat{y} = 1$
- (2) $\hat{y} = -1$

解答例



与えられた条件下で以下を解けば良い。

$$w_j := w_j + \Delta w_j \quad (\text{今回は } j \in \{0, 1, 2\})$$

$$\Delta w_j = \eta(y - \hat{y})x_j$$

$$(1) \Delta w_0 = 0.5(1 - 1) \mathbf{1} = 0$$

$$\Delta w_1 = 0.5(1 - 1)1 = 0$$


$$\Delta w_2 = 0.5(1 - 1)0.5 = 0$$

よって、更新後の重みは以下ようになる：

$$\mathbf{w} := \mathbf{w} + \Delta \mathbf{w} = \begin{bmatrix} 0 \\ 0.5 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.5 \\ 1 \end{bmatrix}.$$

すなわち、 **w は学習前と同じ(更新されない)**。

解答例 (続き)



与えられた条件下で以下を解けば良い。

$$w_j := w_j + \Delta w_j \quad (\text{今回は } j \in \{0, 1, 2\})$$

$$\Delta w_j = \eta(y - \hat{y})x_j$$

$$(2) \Delta w_0 = 0.5(1 - (-1)) \mathbf{1} = 0.5 \times 2 \times \mathbf{1} = \mathbf{1}$$

$$\Delta w_1 = 0.5(1 - (-1))1 = 0.5 \times 2 \times 1 = 1$$

$$\Delta w_2 = 0.5(1 - (-1))0.5 = 0.5 \times 2 \times 0.5 = 0.5$$

よって、更新後の重みは以下ようになる:

$$\mathbf{w} := \mathbf{w} + \Delta \mathbf{w} = \begin{bmatrix} 0 \\ 0.5 \\ 1 \end{bmatrix} + \begin{bmatrix} \mathbf{1} \\ 1 \\ 0.5 \end{bmatrix} = \begin{bmatrix} \mathbf{1} \\ 1.5 \\ 1.5 \end{bmatrix}.$$

すなわち、学習により重みが変わった。

解答例 (2) に基づくラベルの予測

いま、 $w = \begin{bmatrix} \mathbf{1} \\ 1.5 \\ 1.5 \end{bmatrix}$ の状態まで学習を進めた。


この状態のモデルを用いて、

真のラベルが $y = 1$ となるサンプルデータ $x' = \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix}$

の予測値 \hat{y} は以下のように計算する:

$$\begin{aligned} \hat{y} &= \phi(w^T x') = \phi \left(\begin{bmatrix} \mathbf{1} & 1.5 & 1.5 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} \right) \quad (;\text{ ㄥ })\text{トホホ...} \\ &= \phi(\mathbf{1} - 1.5 - 1.5) = \phi(\mathbf{-2}) = -1 \end{aligned}$$

つまり、 $y \neq \hat{y}$ となり**予測失敗**である。






学習手続きの収束について

学習手続きが収束するのは、

データセットが2つのクラスに線形分離可能かつ

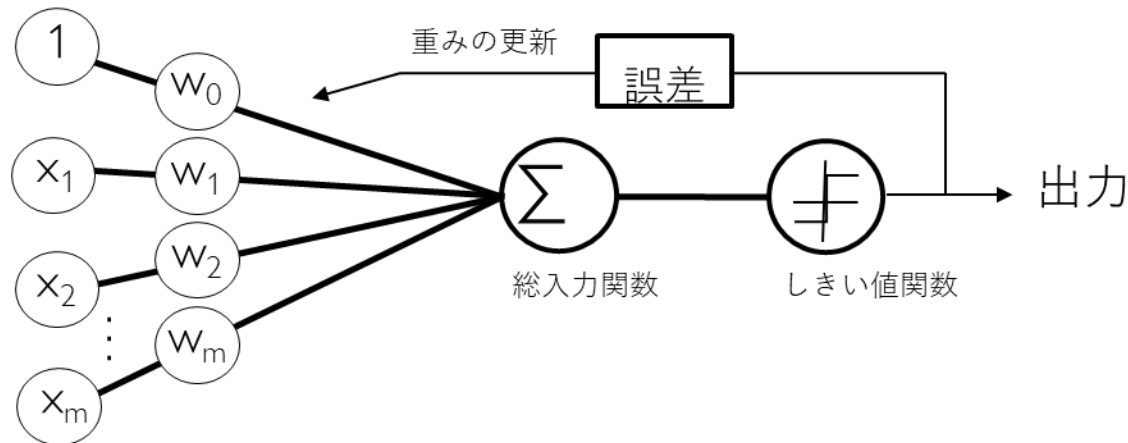
学習率が十分小さい場合のみ。



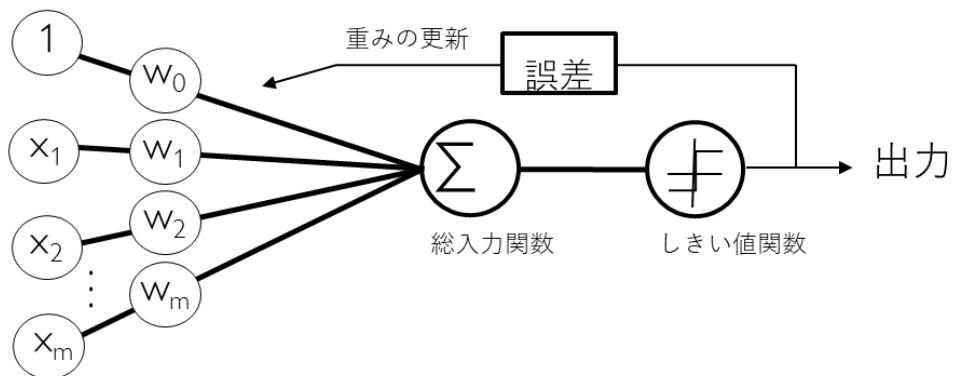
実用上、**訓練の最大回数(エポック)**や**誤分類の最大回数**を
学習の終了条件に含めて学習手続きが終了することを保証する。

Quiz: パーセプトロンのモデルの拡張

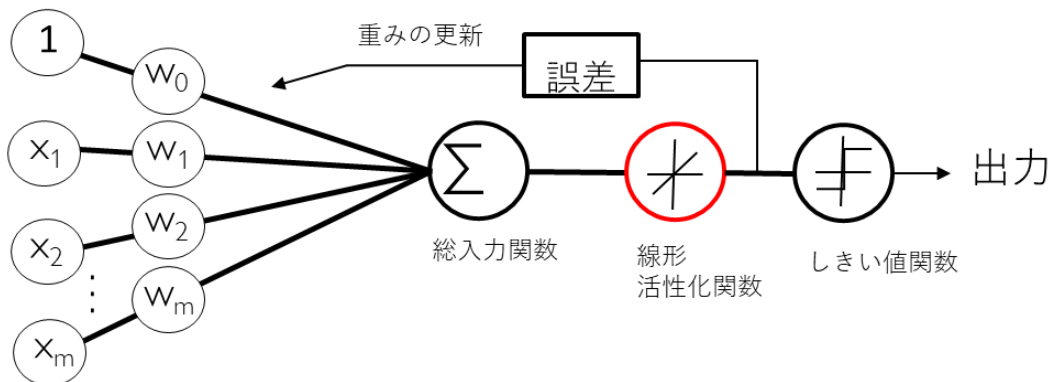
皆さんだったら、以下のパーセプトロンのモデルを
どのように改良・拡張しますか？



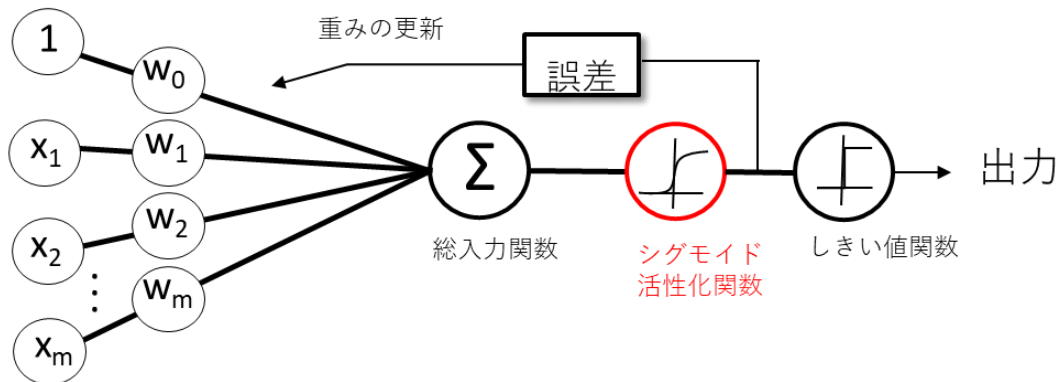
パーセプトロンを拡張したモデル



… パーセプトロン



… ADALINE




… ロジスティック回帰

Adaptive Linear NEuron

ADALINE

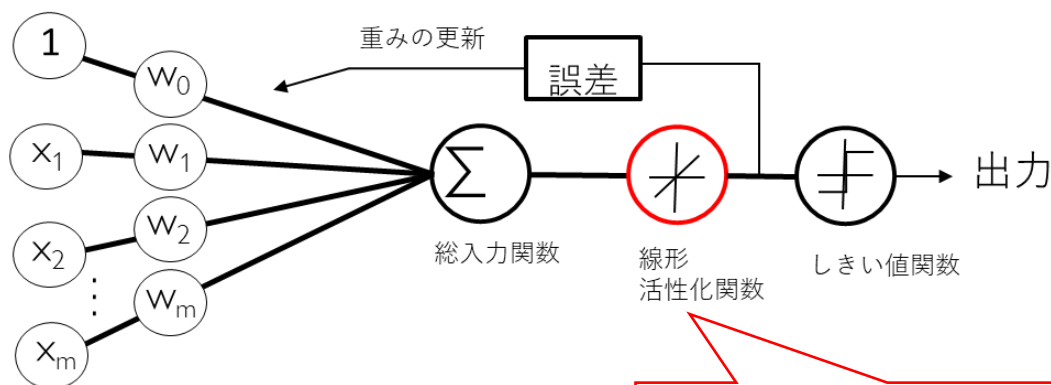


B. Widrow



M. Hoff

学習時に、訓練データ x^i の真のクラスラベル y^i と
線形活性化関数からの出力値 $\phi(z^i)$ を比較する。



線形活性化関数

$$\phi(z) = z$$

要するに、**恒等関数**で
出力は連続値となる。
(単なる-1 or 1ではない)

ADALINEの学習規則

1. 重みベクトル w を初期化する (0 or 乱数)
2. 各訓練データ x^i ごとに以下の計算をする:
 1. 予測値 \hat{y}^i を計算する:

$$\hat{y}^i = \phi(z^i),$$

ただし $z^i = w^T x^i$ である。


2. 重みベクトル w を更新する:

$$w := w + \Delta w$$

$$\Delta w_j = \eta \sum_i (y^i - \hat{y}^i) x_j^i$$

訓練データごとに小刻みに更新するのではなく、**訓練データ全体**で更新する。

ただし、 η は学習率 (0~1の実数値)、
 y^i は訓練データ x^i の真のラベル、
 \hat{y}^i は訓練データ x^i の予測値のラベルである。



勾配降下法

パーセプトロンと違って
損失関数は微分可能 & 凸関数なので
損失を最小化する重みを発見できる！




いいなあ...

Mean-squared Error

ADALINEは以下の損失関数 L （平均二乗誤差）を
目的関数とする勾配降下法によって学習をしている：

$$L(w, b) = \frac{1}{2n} \sum_i^n (y^i - \hat{y}^i)^2$$

$$\phi(z^i) = z^i$$



重みの変化

$$\begin{aligned} \Delta w &= -\eta \nabla L(w) = -\eta \frac{\delta L}{\delta w_j} \\ &= \eta \sum_i (y^i - \hat{y}^i) x_j^i \end{aligned}$$

コストの **大域的** 最小値

$$L_{\min}(w)$$

学習率の設定が良くないと…

大域的最小値を超えてしまい、収束しづらくなる。

